

Entregable 2

Alex Pérez

30 de octubre de 2024

Machine Learning Applied for Cybersecurity of Energy Management Systems

(Aprendizaje Automático Aplicado a la Ciberseguridad del Manejo de Sistemas Energéticos)

Tutor: Felipe Grijalva

Autor: Alex Pérez

Visualización del Dataset Original

	Demand									
1	10729	11031	11081	11132	11139	11194	11607	30051	30079	
2	69.04000000000002	39.41917999999998	14.39	37.43	71.99999999999999	63.570000000000014	43.43000000000001	25.26	21.24	
3	71.92	38.38917999999999	13.99999999999998	38.940000000000026	70.99	62.220000000000056	38.57	24.630000000000003	21.1	
4	67.390000000000001	32.53918000000001	13.96	62.780000000000005	63.180000000000014	60.76	34.30000000000001	26.05	21.16	
5	65.75999999999999	29.629179999999995	13.90999999999998	31.249999999999975	50.56999999999998	49.18999999999999	31.40999999999997	31.49	21.03	
6	64.36	27.999180000000001	14.010000000000002	30.219999999999985	47.269999999999975	41.410000000000001	26.140000000000008	34.2	19.62	
7	63.38	26.959179999999986	14.09	31.799999999999976	42.96	38.509999999999984	25.110000000000007	37.91	15.31	
8	64.95	27.879180000000001	13.99	28.619999999999965	44.490000000000016	40.680000000000014	24.62	42.82	15.239999999999998	
9	65.42	28.169179999999987	14.71	31.55999999999998	46.18999999999998	46.670000000000003	29.159999999999997	48.86	15.27	
10	68.820000000000001	29.779180000000007	16.599999999999998	36.84	54.43999999999998	50.960000000000005	31.15	48.92999999999999	15.44	
11	74.84	34.63918	15.82	43.780000000000003	69.6	75.020000000000001	34.68	47.18	15.3	
12	71.710000000000001	46.35918000000001	15.47	47.260000000000003	77.92999999999998	82.610000000000001	40.299999999999999	46.62	15.22	
13	73.100000000000002	44.309180000000002	15.739999999999998	51.140000000000015	88.67999999999998	86.47	48.57999999999999	46.61	15.4	
14	74.06	42.069180000000002	15.829999999999998	85.01	99.71	75.530000000000006	42.73	46.26	15.47	
15	73.0	41.159180000000006	14.29	93.540000000000003	97.24999999999999	89.83999999999997	40.64	46.38	15.54	
16	75.48999999999998	44.049180000000001	14.34	78.39999999999998	98.220000000000003	86.60999999999997	44.570000000000014	47.16	15.509999999999998	
17	80.21	43.31918	14.929999999999998	55.430000000000001	102.88999999999992	91.510000000000003	50.419999999999995	54.03	15.48	
18	81.430000000000002	58.939180000000004	15.05	71.93999999999997	124.38	123.710000000000002	68.860000000000003	51.8	15.509999999999998	
19	83.95	68.579180000000002	14.959999999999996	92.000000000000003	142.64999999999998	148.24999999999997	74.98	42.74	15.4	
20	82.96	67.25918	15.249999999999998	96.340000000000003	128.410000000000005	131.220000000000003	64.83999999999997	28.42	15.46	
21	76.73	58.659179999999999	14.11	77.97999999999992	116.24999999999996	109.07999999999998	50.180000000000014	27.75	15.87	
22	76.15	62.109180000000002	12.74	66.100000000000001	98.0	98.82	48.510000000000002	37.74	15.82	

Figura: Dataset de Demanda

Dataset Utilizado

Datos de Entrenamiento:

- Cada transformador tiene 25,000 mediciones temporales.
- Dataset total: 17 transformadores.

Distribución de Datos:

- **Entrenamiento:** Datos 0 a 17,500.
- **Validación:** Datos 17,501 a 20,000.
- **Testing (prototipo FDIA):** Datos 20,001 a 22,500.
- **Evaluación final FDIA:** Últimos 2,500 datos.

Frecuencia de las Mediciones:

- Cada medición representa 1 hora de datos, lo que implica un total de 25,000 horas.

Frecuencia Fundamental y Ciclo Diario (Análisis Espectral)

Frecuencia Fundamental:

- Frecuencia identificada: $f \approx 0.0418$ Hz.
- Esta frecuencia corresponde a un ciclo completo cada 24 horas.

Relación Matemática:

$$T = \frac{1}{f} = \frac{1}{0.0418} \approx 24 \text{ horas} \quad (1)$$

Interpretación:

- Relación con el tamaño de ventana: un ciclo completo captura la variabilidad cíclica diaria de la demanda energética.

Ventana de Aprendizaje (sin Análisis Espectral)




Figura: 10023 T&V vs WindowSize




Figura: 10193 T&V vs WindowSize




Figura: 10292 T&V vs WindowSize



Figura: 30118 T&V vs WindowSize

Resultados de Evaluación de Modelos por Transformador (Conjunto de Test / Ventana de 24 horas)

M./T.	10023	10193	10292	10370	10729	11031	11081	11132	11139	11194	11607	30051	30079	30086	30095	30110	30118
	LSTM (improved: 128 hidden dim., 3 layers, dropout 30 %)																
MSE	0.0048	0.0059	0.0091	0.0045	0.0035	0.0058	0.0046	0.0096	0.0047	0.0035	0.0091	0.0025	0.0013	0.0070	0.0016	0.0055	0.0030
MAE	0.0507	0.0556	0.0720	0.0528	0.0430	0.0589	0.0330	0.0753	0.0526	0.0438	0.0725	0.0354	0.0207	0.0539	0.0279	0.0532	0.0360
RMSE	0.0691	0.0771	0.0956	0.0670	0.0589	0.0762	0.0675	0.0979	0.0685	0.0590	0.0956	0.0500	0.0356	0.0835	0.0397	0.0743	0.0543
R²	0.8807	0.7732	0.6468	0.9199	0.8315	0.8070	0.7660	0.7712	0.8216	0.8641	0.6539	0.9617	0.9804	0.8941	0.9819	0.8175	0.9402
	TRANSFORMERS																
MSE	0.0093	0.0080	0.0100	0.0089	0.0048	0.0087	0.0068	0.0173	0.0067	0.0064	0.0100	0.0070	0.0014	0.0121	0.0084	0.0086	0.0094
MAE	0.0745	0.0679	0.0780	0.0755	0.0541	0.0723	0.0542	0.0996	0.0601	0.0607	0.0763	0.0552	0.0195	0.0712	0.0563	0.0713	0.0792
RMSE	0.0964	0.0893	0.1002	0.0945	0.0690	0.0934	0.0824	0.1317	0.0820	0.0797	0.1002	0.0838	0.0375	0.1102	0.0919	0.0926	0.0971
R²	0.7676	0.6958	0.6123	0.8404	0.7690	0.7104	0.6518	0.5859	0.7447	0.7521	0.6195	0.8925	0.9783	0.8157	0.9032	0.7161	0.8091
	TCN																
MSE	0.0091	0.0081	0.0100	0.0096	0.0043	0.0080	0.0069	0.0158	0.0071	0.0068	0.0098	0.0079	0.0021	0.0109	0.0081	0.0079	0.0059
MAE	0.0755	0.0700	0.0762	0.0776	0.0498	0.0691	0.0580	0.0963	0.0606	0.0596	0.0734	0.0668	0.0363	0.0663	0.0596	0.0660	0.0483
RMSE	0.0954	0.0902	0.1001	0.0980	0.0658	0.0897	0.0832	0.1257	0.0841	0.0822	0.0989	0.0886	0.0457	0.1046	0.0901	0.0889	0.0770
R²	0.7723	0.6896	0.6133	0.8285	0.7898	0.7331	0.6450	0.6231	0.7316	0.7364	0.6294	0.8799	0.9677	0.8338	0.9070	0.7384	0.8799

Comparación de Modelos Predictivos (LSTM, TCN y Transformers)

- Se analizaron los modelos en términos de las métricas RMSE y R^2 .
- Los valores promedio de las métricas fueron calculados para cada modelo en todos los transformadores.

```
RMSE Promedio - LSTM: 0.0688  
RMSE Promedio - Transformers: 0.0901  
RMSE Promedio - TCN: 0.0887  
-----  
R2 Promedio - LSTM: 0.8419  
R2 Promedio - Transformers: 0.7567  
R2 Promedio - TCN: 0.7646
```

- **LSTM** resultó ser el mejor modelo con un RMSE promedio más bajo y un R^2 promedio más alto.
- **TCN** mostró un RMSE promedio y R^2 promedio ligeramente mejores que **Transformers** → se propone un **Modelo Híbrido** que combine **LSTM y TCN**.

Resultados de Evaluación de Modelos por Transformador (Conjunto de Test / Ventana de 24 horas)

M./T.	10023	10193	10292	10370	10729	11031	11081	11132	11139	11194	11607	30051	30079	30086	30095	30110	30118
	HYBRID (TCN + LSTM (standard: 64 hidden dim., 1 layer, dropout 20 %))																
MSE	0.0047	0.0064	0.0089	0.0046	0.0040	0.0060	0.0072	0.0091	0.0050	0.0032	0.0103	0.0023	0.0031	0.0064	0.0015	0.0050	0.0030
MAE	0.0498	0.0610	0.0711	0.0523	0.0461	0.0581	0.0584	0.0734	0.0536	0.0417	0.0759	0.0353	0.0405	0.0496	0.0275	0.0522	0.0366
RMSE	0.0687	0.0801	0.0946	0.0677	0.0632	0.0775	0.0849	0.0955	0.0705	0.0568	0.1017	0.0484	0.0554	0.0797	0.0392	0.0707	0.0546
R ²	0.8820	0.7552	0.6547	0.9181	0.8064	0.8008	0.6299	0.7825	0.8111	0.8743	0.6082	0.9642	0.9525	0.9035	0.9823	0.8348	0.9397
	HYBRID (TCN + LSTM (improved: 128 hidden dim., 3 layers, dropout 30 %))																
MSE	0.0051	0.0060	0.0094	0.0059	0.0038	0.0060	0.0091	0.0085	0.0054	0.0040	0.0099	0.0023	0.0025	0.0066	0.0027	0.0046	0.0030
MAE	0.0521	0.0589	0.0732	0.0596	0.0475	0.0593	0.0736	0.0707	0.0550	0.0458	0.0762	0.0354	0.0312	0.0531	0.0366	0.0506	0.0355
RMSE	0.0714	0.0776	0.0968	0.0769	0.0619	0.0773	0.0954	0.0924	0.0734	0.0631	0.0995	0.0484	0.0501	0.0811	0.0516	0.0681	0.0548
R ²	0.8723	0.7698	0.6382	0.8943	0.8144	0.8015	0.5331	0.7960	0.7952	0.8447	0.6250	0.9641	0.9611	0.9001	0.9694	0.8465	0.9391

Comparación de Modelos Híbridos con Modelo LSTM

- Se evaluaron las métricas RMSE y R^2 .

```
RMSE Promedio - LSTM: 0.0688  
RMSE Promedio - Hybrid ST: 0.0711  
RMSE Promedio - Hybrid Improved: 0.0729  
-----  
 $R^2$  Promedio - LSTM: 0.8419  
 $R^2$  Promedio - Hybrid ST: 0.8294  
 $R^2$  Promedio - Hybrid Improved: 0.8215
```

- LSTM** mantuvo el mejor rendimiento global.
- Se propone utilizar solamente esta arquitectura para modelo MIMO.

One-Class SVM para la Detección de Anomalías

- No requiere datos etiquetados.
- Menos dependiente de la distribución.
- Enfoque en una sola clase.
- Fácil de ajustar.

Lo que se va a hacer:

- Obtener las predicciones, usando el modelo LSTM, de nuevos datos *normales* proporcionados.
- Entrenar el modelo One-Class SVM con dichas predicciones.
- Usar One-Class SVM para detectar posibles anomalías en nuevos datos.

Detección de anomalías - Nuevos Datos *normales*

- Para el transformador 30095, con $R^2 = 0.9839$ y $RMSE = 0.0375$.

```
Cantidad total de datos analizados: 2476  
Cantidad total de anomalías detectadas: 25  
Porcentaje de datos marcados como anomalías: 1.01%
```

Detección de anomalías - Nuevos Datos *infectados*

- Para el transformador 30095, con $R^2 = 0.9839$ y $RMSE = 0.0375$.
- Con un factor de ruido de 0.3. El factor de ruido de 0.3 indica que se han añadido desviaciones aleatorias a los valores originales, con una amplitud del 30 % de la magnitud del dato original.

```
Cantidad total de datos analizados: 2476  
Cantidad total de anomalías detectadas: 916  
Porcentaje de datos marcados como anomalías: 37.00%
```

Referencias

- [1] Zhang, Y., Wang, X., & Liu, J. (2020). Detecting False Data Injection Attacks in Smart Grids Using CNNs and LSTMs. *IEEE Transactions on Smart Grid*, 11(4), 3043-3051. <https://arxiv.org/pdf/2006.11477>.
- [2] Stanford University. (2024). Recurrent Neural Networks cheatsheet. Recuperado de <https://stanford.edu/~shervine/teaching/cs-230/cheatsheet-recurrent-neural-networks>.
- [3] Cayci, S., & Eryilmaz, A. (2024). Convergence of Gradient Descent for Recurrent Neural Networks: A Nonasymptotic Analysis. *arXiv preprint arXiv:2402.12241*. Recuperado de <https://arxiv.org/abs/2402.12241>.
- [4] Staudemeyer, R. C., & Morris, E. R. (2019). Understanding LSTM – a tutorial into Long Short-Term Memory Recurrent Neural Networks. *arXiv preprint arXiv:1909.09586*. Recuperado de <https://arxiv.org/abs/1909.09586>.